
Title

Name Surname
MIPT
Moscow, Russia
email@phystech.edu

Name Surname
MIPT
Moscow, Russia
email@phystech.edu

Abstract

В данной работе решается задача детекции строк на фотографиях страниц рукописного текста на русском языке. Основная сложность заключается в обработке изображений с высоким уровнем шума, неравномерным, слабым освещением, геометрическими искажениями, а также наличием посторонних предметов на фотографии. Дополнительной проблемой является расположение строк, отличное от последовательности горизонтальных линий. В результате исследования планируется разработать новый алгоритм, который качественно превосходить существующие. Разработанные методы могут найти применение, например, в задачах распознавания древних исторических текстов.

Keywords: TODO

1 Introduction

Детекция строк зачастую является необходимым этапом при распознавании рукописных текстов — так как модели распознавания работают на уровне строк. Она заключается в выделении на изображении отдельных элементов — текстовых строк. Качество работы всей системы распознавания рукописного текста напрямую зависит от результатов этого этапа: ошибки в выделении строк неизбежно приводят к снижению точности распознавания. Таким образом, разработка эффективного и надёжного метода детекции строк представляет собой актуальную задачу.

На пути к решению задачи возникает ряд проблем. Основными из них являются: непостоянство наклона строк текста в изображении, взаимное наложение строк друг на друга, неудовлетворительные условия освещения.

1.1 Постановка задачи

1.1.1 Дано

Набор изображений страниц с рукописным текстом на русском языке: $\mathcal{I} = \{I_k\}_{k=1}^K$, где каждое $I_k \in \mathbb{R}_+^{H_k \times W_k \times C}$, H_k — высота, W_k — ширина, C — количество каналов. Для каждого изображения I_k задано множество: $\mathcal{R}_k = \{R_{k,1}, \dots, R_{k,n_k}\}$, где каждое $R_{k,j}$ — множество точек, которые задают минимальный ограничивающий прямоугольник j -й строки текста, а n_k — количество строк на изображении. Под строкой текста понимается последовательность рукописных символов и слов, расположенных вдоль одной локально гладкой траектории письма и отделённая от соседних строк межстрочным промежутком. Датасет: $\mathcal{D} = \{(I_k, \mathcal{R}_k)\}_{k=1}^K$.

1.1.2 Найти

Построить отображение

$$f: \mathcal{I} \rightarrow 2^B,$$

где

$$B = \{ \{p_i\}_{i=1}^4 \mid p_i = (x_i, y_i) \in \mathbb{Z}_{\geq 0}^2, \text{ точки } p_1, p_2, p_3, p_4 \text{ являются вершинами прямоугольника} \}.$$

По входному изображению $I \in \mathcal{I}$ отображение f предсказывает набор минимально ограничивающих прямоугольников:

$$f(I) = \hat{\mathcal{R}} \subseteq 2^B.$$

Необходимо, чтобы для любого предсказанного прямоугольника

$$R = \{p_i\}_{i=1}^4 \in \hat{\mathcal{R}}, \quad p_i = (x_i, y_i),$$

выполнялось условие принадлежности всех его вершин области изображения:

$$p_i \in \Omega_I, \quad \Omega_I = \{0, \dots, W\} \times \{0, \dots, H\}, \quad i = 1, \dots, 4.$$

Здесь H и W — высота и ширина изображения I .

1.1.3 Критерий

Для каждой пары предсказанного и истинного полигонов считается Intersection over Union:

$$\text{IoU}(\hat{R}_i, R_j) = \frac{|\hat{R}_i \cap R_j|}{|\hat{R}_i \cup R_j|}.$$

Сопоставление выполняется жадно. Для каждого предсказанного полигона $\hat{R}_i$ выбирается ещё не занятый ground truth полигон R_j с максимальным значением IoU:

$$j^* = \arg \max_{j \in \mathcal{R}_{\text{free}}} \text{IoU}(\hat{R}_i, R_j).$$

Если

$$\text{IoU}(\hat{R}_i, R_{j^*}) \geq 0.5,$$

то такая пара считается true positive (TP).

Если подходящего ground truth полигона не найдено, предсказание считается false positive (FP).

Все ground truth полигоны, которые не были сопоставлены ни с одним предсказанием, считаются false negative (FN).

Итоговые метрики считаются следующим образом:

$$\begin{aligned} \text{precision} &= \frac{TP}{TP + FP}, \\ \text{recall} &= \frac{TP}{TP + FN}, \\ \text{hmean} &= \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}. \end{aligned}$$

1.1.4 Литература

В литературе представлен ряд подходов для решения данной задачи. Классические методы машинного обучения, такие как метод горизонтальных проекций [1], преобразование Хафа [2], алгоритмы размазывания [3], чаще всего решают задачу, не учитывая все вышеперечисленные проблемы. Только их комбинирование с другими методами может привести к приемлемому результату [4].

Также есть нейросетевые подходы, которые всё чаще [5] используются для решения данной задачи. [6] Используются трансформеры для нахождения матриц вероятности и порогов для последующей бинаризации и выделения текста. Нейросетевые методы, обучение без учителя такие как UTLS [7] очень чувствителен к сильной неоднородности структуры документа.

В современной литературе почти никогда не учитывается тип языка при распознавании строк, и работа ведётся с хорошо освещёнными отсканированными изображениями.

2 Related Work

Метод UTLS [7] чувствителен к сильной неоднородности структуры документа: большим различиям в высоте строк, межстрочных расстояниях, наклонах и форме строк. Это связано с тем, что размер анализируемого патча выбирается относительно средней высоты символов или строк, поэтому при сильных перепадах масштаба один и тот же размер окна может быть подходящим для одних строк и неподходящим для других.

Метод Kurar Barakat [8] демонстрирует высокое качество на исторических рукописных документах: на DIVA—HisDB авторы сообщают достижение Line IU до 100%, а на cBAD получают результаты, близкие к лучшим learning—free подходам, хотя уступающие лучшему learning—based методу с F—measure 97.70. При этом метод является вычислительно затратным: полный прогон по cBAD занимает около одного дня. Основные ограничения подхода связаны с высокой зависимостью от оценки высоты символов, ухудшением качества при сильном наклоне строк, появлением ложных blob lines и неточным разделением касающихся символов соседних строк.

3 Preliminaries

4 Experiments

4.0.1 Преобразование Хафа

Наша команда пробовала метод, основанный на преобразовании Хафа [4], данный подход имеет ряд недостатков.

Во-первых он очень зависит от качества бинаризации. Если, к примеру, какой-то метод бинаризации после себя оставит ряд мелких чёрных пикселей, это усложнит задачу подсчёта средней ширины или высоты компонент (смотри рис. 1a).

Во-вторых иногда несколько слов в идущих подряд строках могут образовывать одну компоненту связности, метод в статье не умеет разделять такие компоненты, а также в голосовании Хафа все они не будут участвовать что создаст сильную неоднородность количества голосующих точек между строками (смотри рис. 1b).

В-третьих необходимо подбирать гиперпараметры: порог голосов для основной линии порог для дополнительных линий радиус окрестности для объединения голосов порог отклонения угла для отбрасывания строк и многие другие.


В-четвёртых метод поиска, предложенный авторами, дополнительных строк значительно понижает precision и лишь немного увеличивает recall.

Мы предлагаем следующие решения данных проблем:

1) Вместо выбора самой частой высоты брать среднее используя робастность, будем отсекал первый бин считая его шумом бинаризации (смотри рис. 2b).

2) Мы предлагаем для начала разделить subset_2. Это даст возможность всем словам участвовать в голосовании. Для этого мы смотрим на все связные компоненты из subset_2 и с помощью метода, описанного в статье [9] предварительно предварительно максимизировав дисперсию HPP с помощью поворота разделяем слова. Добавляем получившиеся компоненты в subset_1 и только после этого проводим голосование Хафа (смотри рис. 2a).

не представляю себе Россию без корыстных
и алчных элитовиков. Для многих из нас
взрыв стала мечтой жизни, как для многих
знающих выживших, борьба с которыми
увеличилась лишь из-за колоссальных
ущербов. В то же время, есть еще в. Солонин,
это был современник. Будто не соглашаясь
с автором. Ведь на сегодняшний день коррупция
для нашей страны - это своеобразная форма
какого-то расщепленного, легкого, выжидания.
Среди нас, правда, то может произойти




(a) Пример множества маленьких компонент при плохой бинаризации.

(b) Пример связной компоненты слов из нескольких подряд идущих строк.


3) Наша команда не смогла найти полное решение данной проблемы. Однако ряд гиперпараметров возможно заменить на менее чувствительные а именно диапазон углов в матрице голосования можно задавать так: сначала оценивать глобальный угол наклона строк с помощью максимизации дисперсии `hrr` потом с помощью гиперпараметра задавать отклонения относительно этого угла, это делает метод гораздо устойчивее. Также был установлен один гиперпараметр для слияния линий и добавления новых на который домножается среднее значение расстояния между предсказанными линиями в проекции на вертикаль посреди изображения. Была введена проверка для новых линий что их угол лежит в диапазоне углов в матрице голосования

4) Наша команда решила убрать данную стадию, учитывая тот факт, что датасет состоит из сочинений и строки на фотографиях имеют примерно одинаковую длину.



(a) Пример разделения `subset_2`.

Height histogram: all bins



(b) Пример гистограммы с отсечением первого бина.

4.0.2 Сравнение метода из статьи и нашего метода

Наша команда провела эксперимент на датасете [10]. Были взяты 1569 изображений в качестве тестовой выборки из них было выделено 20, с помощью Optuna был произведён перебор гиперпараметров для метода (40 шагов, оптимизатор: optuna.samplers.TPESampler). На всех 1569 изображениях мы сравнили метод авторов и наш с внесёнными вышеописанными изменениями, в качестве предобработки в обоих случаях использовались модели U-Net и Yolo обученные на бинаризацию и сегментацию страниц текста соответственно.

Table 1: Сравнение метрик качества детекции строк

Метод	Precision	Recall	Hmean
Paper method	0.4519	0.5472	0.4950
Our method	0.7426	0.7955	0.7681

4.0.3 Вывод

В целом метод имеет большое количество гиперпараметров, что делает его применение сложным.

4.0.4 Горизонтальный профиль проекции

Мы также пробовали метод, основанный на горизонтальном профиле проекции [9], данный подход имеет ряд недостатков:

- 1) Метод вообще не учитывает наклон строк даже глобальный (смотри рис. 3а рис. 3б).
- 2) Анализ профиля проекции производится крайне поверхностно, задан один гиперпараметр порогового значения. Факт одинаковости строк по длине вовсе не гарантирует, что пики в профиле проекции будут примерно одинаковыми. В какой-то строке могут быть большие промежутки между словами, более размашистый почерк.

Наше улучшение методов на основе горизонтального профиля проекции:

- 1) Учёт глобального и локального наклона строк (смотри рис. 3с)

Перед вычислением локальных углов $\alpha(x, y)$ наша команда сначала исправляет глобальный наклон страницы:

1. Бинаризуем изображение $B(x, y)$:

$$B(x, y) = \begin{cases} 0, & \text{фон} \\ 1, & \text{текст} \end{cases}$$

2. Оцениваем глобальный угол θ_{global} методом горизонтальных проекций:

$$\theta_{\text{global}} = \arg \max_{\theta \in [-30^\circ, 30^\circ]} \text{Var} \left(\sum_y B_\theta(x, y) \right)$$

где B_θ — бинаризованное изображение, повернутое на угол θ .

3. Применяем вращение изображения на угол $-\theta_{\text{global}}$:


$$B_{\text{corrected}} = \text{rotate}(B, -\theta_{\text{global}})$$

Далее делаем локальное выпрямление:


1. Делим изображение на сетку $G_x \times G_y$.
2. Для каждой ячейки вычисляем локальный угол наклона $\alpha(x, y)$:

$$\alpha(x, y) = \text{local_angle} \left(B_{\text{cell}}(x, y) \right)$$


где local_angle также оценивается через горизонтальный профиль внутри ячейки (аналогично глобальному методу).



(а) Пример, где НРР работает плохо без исправления глобального наклона: исходное изображение.



(b) Пример, где НРР работает плохо без исправления глобального наклона: энергетическая матрица.



(с) Пример работы после выравнивания и коррекции глобального наклона: энергетическая матрица.

3. Далее строим наклон $s(x, y) = \tan \alpha(x, y)$ и интегрируем вдоль горизонтали для корректного смещения пикселей:

$$dy(x, y) = \sum_{t=0}^{x-1} s(t, y), \quad dy(x, y) \leftarrow dy(x, y) - \frac{1}{W} \sum_{x=0}^{W-1} dy(x, y)$$

4. Наконец, строим преобразование для выпрямления текста:

$$T(x, y) = (x, y + dy(x, y)), \quad B_{\text{warp}}(x, y) = B_{\text{corrected}}(T(x, y))$$

2) Морфологический анализ горизонтального профиля (НРР)

После выпрямления профиля строки $H = [h_1, h_2, \dots, h_n]$ выполняется нормализация НРР:

$$\tilde{H} = \frac{H - \min(H)}{\max(H) - \min(H)}$$

Далее применяются операции closing и opening с ядром размера k :

$$H_{\text{smoothed}} = \text{open}(\text{close}(\tilde{H}, k), k)$$

$$\text{open}(H, k)[y] = \max_{t \in S} \min_{s \in S, y+s+t \in [0, H-1]} H[y + s + t]$$

$$\text{close}(H, k)[y] = \min_{t \in S} \max_{s \in S, y+s+t \in [0, H-1]} H[y + s + t]$$

$$S = \{-\lfloor k/2 \rfloor, \dots, 0, \dots, \lfloor k/2 \rfloor\}$$

И обратно масштабируется в исходный диапазон:

$$H_{\text{final}} = H_{\text{smoothed}} \cdot (\max(H) - \min(H)) + \min(H)$$

На сглаженном профиле H_{final} определяется набор регионов так: мы идём по профилю если видим подъём на 5% относительно текущего уровня и больше затем спуск аналогично на 5% и более — это регион строки текста. Мы используем несколько размеров ядра k_1, k_2 (берём ядра, деля среднюю высоту посчитанную как описано выше на 2 и на 3) и выбираем вариант, дающий максимальное количество строк.

Был проведён аналогичный предыдущему эксперимент с предварительным подбором гиперпараметров. Результат следующий:

Table 2: Сравнение результатов двух методов HPP seam carving.

Method	H-mean	Precision	Recall
Paper method	0.7337	0.8492	0.6458
Our method	0.8419	0.8494	0.8345

4.0.5 Нейросетевые подходы

Наша команда пробовала обучать нейросетевую модель описанную в статье [6] на датасете [10] с предварительной разметкой моделей PaddleOCR-VL (1.5). Результаты по метрикам вышли следующие:

Table 3: Метрики качества DBNet++.

Method	H-mean	Precision	Recall
DBNet++	0.9577	0.9805	0.9359

5 Discussion

TODO

6 Conclusion

TODO

References

- [1] R. Manmatha and J. L. Rothfeder. A scale space approach for automatically segmenting words from historical handwritten documents. IEEE Transactions on Pattern Analysis and Machine Intelligence, 27(8):1212–1225, 2005. URL <https://ciir-publications.cs.umass.edu/getpdf.php?id=505>.
- [2] L. Likforman-Sulem, A. Hanimyan, and C. Faure. A hough based algorithm for extracting text lines in handwritten documents. In Proceedings of the Third International Conference on Document Analysis and Recognition (ICDAR’95), pages 774–777, Montreal, Canada, 1995. IEEE.

- [3] Z. Shi and V. Govindaraju. Line separation for complex document images using fuzzy runlength. In First International Workshop on Document Image Analysis for Libraries (DIAL'04), page 306. IEEE, 2004.
- [4] Pratikakis Halatsis Louloudis, Gatos. Text line detection in handwritten documents. Pattern Recognition, 10(2):6–12, 2008. doi: 10.1016/j.patcog.2008.05.011. URL <https://sci-hub.ru/10.1016/j.patcog.2008.05.011>.
- [5] Pratikakis Halatsis Louloudis, Gatos. Text line detection in handwritten documents. Pattern Recognition, 43(8):781–795, 2025. doi: 10.1007/s10032-025-00526-w. URL <https://link.springer.com/article/10.1007/s10032-025-00526-w>.
- [6] Minghui Liao, Zhisheng Zou, Zhaoyi Wan, Cong Yao, and Xiang Bai. Real-time scene text detection with differentiable binarization and adaptive scale fusion. arXiv:2202.10304, 2022. URL <https://arxiv.org/abs/2202.10304>. Preprint.
- [7] Berat Kurar Barakat, Ahmad Droby, Reem Alaasam, Boraq Madi, Irina Rabaev, Raed Shammes, and Jihad El-Sana. Unsupervised deep learning for text line segmentation. In Proceedings of the 25th International Conference on Pattern Recognition (ICPR), pages 2304–2311. IEEE, 2020. URL <https://arxiv.org/abs/2003.08632>.
- [8] Learning-free text line segmentation for historical handwritten documents. Applied Sciences, 10(22):8276, 2020. doi: 10.3390/app10228276. URL <https://doi.org/10.3390/app10228276>.
- [9] Mamatarani Das and Mrutyunjaya Panda. Seam carving, horizontal projection profile and contour tracing for line and word segmentation of language independent handwritten documents. Results in Engineering, 18:101110, 2023. doi: 10.1016/j.rineng.2023.101110. URL <https://www.sciencedirect.com/science/article/pii/S2590123023002372>.
- [10] Ivan Potyashin, Mariam Kaprielova, Yury Chekhovich, Alexandr Kildyakov, Temirlan Seil, Evgeny Finogeev, and Andrey Grabovoy. Hwr200: New open access dataset of handwritten text images in russian. Dataset on Hugging Face: [urlhttps://huggingface.co/datasets/AntiplagiatCompany/HWR200](https://huggingface.co/datasets/AntiplagiatCompany/HWR200), 2023. URL <https://huggingface.co/datasets/AntiplagiatCompany/HWR200>. Handwritten text images by 200 writers; 30030 images photographed in different conditions; useful for HTR, OCR, near-duplicate and reuse detection.

A Appendix / supplemental material

A.1 Additional experiments / Proofs of Theorems

TODO