Title

Name Surname
MIPT
Moscow, Russia
email@phystech.edu

Name Surname
MIPT
Moscow, Russia
email@phystech.edu

Abstract

В данной работе решается задача детекции строк на фотографиях страниц рукописного текста на русском языке. Основная сложность заключается в обработке изображений с высоким уровнем шума, неравномерным, слабым освещением, геометрическими искажениями, а также наличием посторонних предметов на фотографии. Дополнительной проблемой является расположение строк, отличное от последовательности горизонтальных линий. В результате исследования планируется разработать новый алгоритм, который качественно превосходить существующие. Разработанные методы могут найти применение, например, в задачах распознавания древних исторических текстов.

Keywords: TODO

1 Introduction

Детекция строк зачастую является необходимым этапом при распознавании рукописных текстов — так как модели распознавания работают на уровне строк. Она заключается в выделении на изображении отдельных элементов — текстовых строк. Качество работы всей системы распознавания рукописного текста напрямую зависит от результатов этого этапа: ошибки в выделении строк неизбежно приводят к снижению точности распознавания. Таким образом, разработка эффективного и надёжного метода детекции строк представляет собой актуальную задачу.

На пути к решению задачи возникает ряд проблем. Основными из них являются: непостоянство наклона строк текста в изображении, взаимное наложение строк друг на друга, диакритические знаки.

В литературе представлен ряд подходов для решения данной задачи. Классические методы машинного обучения, такие как метод горизонтальных проекций [?], преобразование Хафа [?], алгоритмы размазывания [?], чаще всего решают задачу, не учитывая все вышеперечисленные проблемы. Только их комбинирование с другими методами может привести к приемлемому результату [?].

В современной литературе почти никогда не учитывается тип языка при распознавании строк, и работа ведётся с хорошо освещёнными отсканированными изображениями.

2 Related Work

Topic #1. TODO

Topic #2. TODO

39th Conference on Neural Information Processing Systems (NeurIPS 2025).

2.1 Общее описание задачи

Ключевая сложность задачи обусловлена необходимостью обработки фотографий с высоким уровнем шума, неудовлетворительными условиями освещения, наличием геометрических искажений и посторонних объектов на снимках. Отдельным вызовом является расположение строк, отличное от последовательности горизонтальных линий расположение строк в рукописном тексте. Целью работы является создание алгоритма, который решает задачу с высоким качеством.

2.2 Постановка задачи

2.2.1 Дано

- Набор изображений страниц с рукописным текстом: $\mathcal{I} = \{I_k\}_{k=1}^{K}$, где каждое $I_k \in \mathbb{R}_+^{H_k \times W_k \times C}$, H_k — высота, W_k — ширина, C — количество каналов.
- Для каждого изображения I_k задано множество: $\mathcal{R}_k = \{R_{k,1}, \ldots, R_{k,n_k}\}$, где каждое $R_{k,j}$ — множество из 4 точек которые задают минимальный ограничивающий прямоугольник j—й строки, а n_k — количество строк на изображении.
- Датасет: $\mathcal{D} = \{(I_k, \mathcal{R}_k)\}_{k=1}^{K}$.

2.2.2 Найти

- Построить отображение
$$f \colon \mathcal{I} \to 2^B,$$
где
$$B = \{(x_1, y_1), (x_2, y_2), (x_3, y_3), (x_4, y_4) \mid x_i, y_i \in \mathbb{Z}_{\geq 0}\}.$$
По входному изображению $I \in \mathcal{I}$ отображение f предсказывает набор минимально ограничивающих прямоугольников:
$$f(I) = \hat{\mathcal{R}} \subseteq 2^B.$$
- Необходимо, чтобы для любого прямоугольника
$$R = \{(x_1, y_1), (x_2, y_2), (x_3, y_3), (x_4, y_4)\} \in \hat{\mathcal{R}}$$
выполнялось:
$$x_i \in [0, W], \quad y_i \in [0, H],$$
где H, W — высота и ширина изображения I.

2.2.3 Критерий

- Для оценки качества используется метрика Intersection over Union (IoU) между предсказанным bounding box $\hat{R}_i$ и истинным bounding box R_j:
$$\mathrm{IoU}(i, j) = \frac{|\hat{R}_i \cap R_j|}{|\hat{R}_i \cup R_j|}.$$
- Для каждого изображения устанавливается оптимальное соответствие между предсказанными и истинными bbox (с помощью венгерского алгоритма, максимизирующего сумму IoU). Итоговая метрика на датасете определяется как среднее значение:
$$\mathrm{Score} = \frac{1}{K} \sum_{k=1}^{K} \frac{1}{\max(n_k, \hat{n}_k)} \sum_{(i,j) \in \mathrm{matching}_k} \mathrm{IoU}(i, j),$$
где $\mathrm{matching}_k$ — найденное оптимальное соответствие для k—го изображения.

3 Preliminaries

3.1 General notation

In this section, we introduce the general notation used in the rest of the paper and the basic assumptions.

3.2 Assumptions

TODO

4 Method

4.1 Overview

Пусть задано входное изображение

$$I \in \mathbb{R}^{H \times W \times C},$$

где H — высота, W — ширина, C — число каналов. Требуется построить отображение

$$f : \mathcal{I} \to 2^B, \quad \hat{\mathcal{R}} = f(I),$$

где $\hat{\mathcal{R}}$ — множество прямоугольников, соответствующих строкам текста.

Алгоритм реализует последовательное преобразование представления изображения:

$$I \xrightarrow{\Phi_1} B \xrightarrow{\Phi_2} \mathcal{C} \xrightarrow{\Phi_3} (\mathcal{C}_1, \mathcal{C}_2, \mathcal{C}_3) \xrightarrow{\Phi_4} \mathcal{L} \xrightarrow{\Phi_5} \hat{\mathcal{R}}.$$

Здесь:

$$B = \Phi_1(I), \quad B \in \{0,1\}^{H \times W}$$

— бинарное изображение, полученное оператором бинаризации.

$$\mathcal{C} = \Phi_2(B) = \{c_i\}_{i=1}^{N}$$

— множество связных компонент, где каждая компонента

$$c_i = (x_i, y_i, w_i, h_i)$$

задаётся ограничивающим прямоугольником.

$$(\mathcal{C}_1, \mathcal{C}_2, \mathcal{C}_3) = \Phi_3(\mathcal{C})$$

— разбиение компонент по геометрическим характеристикам:

$$\mathcal{C}_1 : \text{базовые символы}, \quad \mathcal{C}_2 : \text{слипшиеся компоненты}, \quad \mathcal{C}_3 : \text{шум и мелкие элементы}.$$

$$\mathcal{L} = \Phi_4(\mathcal{C}_1)$$

— множество параметризованных линий:

$$\ell_k = (\rho_k, \theta_k),$$

полученных с помощью преобразования Хафа.

$$\hat{\mathcal{R}} = \Phi_5(\mathcal{L}, \mathcal{C})$$

— итоговое множество строк, полученное путём проецирования компонент на найденные линии и формирования ограничивающих областей.

4.2 Algorithm

Algorithm 1 Text Line Detection

Require: Image I
Ensure: Set of lines $\mathcal{L}$

$B \leftarrow \text{Binarize}(I)$
$\mathcal{C} \leftarrow \text{ConnectedComponents}(B)$
Estimate:

$$AH = \mathbb{E}[h_i], \quad AW = \mathbb{E}[w_i]$$

Partition components:

$$\mathcal{C}_1 = \{c \in \mathcal{C} \mid 0.5AH \leq h_c < 3AH,\ w_c \geq 0.5AW\}$$
$$\mathcal{C}_2 = \{c \in \mathcal{C} \mid h_c \geq 3AH\}$$
$$\mathcal{C}_3 = \mathcal{C} \setminus (\mathcal{C}_1 \cup \mathcal{C}_2)$$

Split vertically-connected components:

$$\mathcal{C}_1 \leftarrow \mathcal{C}_1 \cup \text{Split}(\mathcal{C}_2)$$

Extract block centers:

$$\mathcal{P} = \bigcup_{c \in \mathcal{C}_1} \{p_{c,i}\}$$

Perform Hough voting:

$$\rho = x \cos\theta + y \sin\theta$$

Detect lines:

$$\mathcal{L} = \{(\rho_k, \theta_k)\}$$

```
while points remain do
    Select (ρ*, θ*) = arg max votes
    if votes < T then
        break
    end if
    Assign components to line
    Remove assigned points
end while
```

Merge close lines:

$$|y_i - y_j| < \lambda \cdot \mathbb{E}[\Delta y]$$

Create new lines:

$$d(p, \mathcal{L}) \approx A_d$$

Assign $\mathcal{C}_3$ to nearest lines:

$$\ell^* = \arg\min_{\ell \in \mathcal{L}} d(c, \ell)$$

return $\mathcal{L}$

4.3 Binarization

$$B(x, y) = \begin{cases} 1, & \text{if } I(x, y) \in \text{text} \\ 0, & \text{otherwise} \end{cases}$$

4.4 Connected Components

$$\mathcal{C} = \{c_i\}, \quad c_i = (x_i, y_i, w_i, h_i)$$

4.5 Hough Transform

$$\rho = x \cos\theta + y \sin\theta, \quad \theta \in [\theta_{\min}, \theta_{\max}]$$

Аккумулятор:

$$A(\rho, \theta) = \sum_{p \in \mathcal{P}} \mathbf{1}(p \in \ell(\rho, \theta))$$

4.6 Line Assignment

Компонента c принадлежит линии ℓ, если:

$$\frac{|\mathcal{P}_c \cap \ell|}{|\mathcal{P}_c|} \geq \frac{1}{2}$$

4.7 Line Merging

Для линий ℓ_i, ℓ_j:

$$|\hat{y}_i - \hat{y}_j| < \alpha \cdot \bar{d}$$

4.8 New Line Creation

Для точки p:

$$d(p, \mathcal{L}) = \min_{\ell \in \mathcal{L}} d(p, \ell)$$

Кандидат:

$$\beta_1 A_d \leq d(p, \mathcal{L}) \leq \beta_2 A_d$$

4.9 Final Assignment

$$\ell^*(c) = \arg\min_{\ell \in \mathcal{L}} d(c, \ell)$$

4.10 Output Representation

Каждая строка:

$$\ell = \{c_1, \ldots, c_m\}$$

Итоговый bounding box:

$$R = \text{ConvexHull}\left(\bigcup_{c \in \ell} \text{pixels}(c)\right)$$

5 Experiments

To verify the theoretical estimates obtained, we conducted a detailed empirical study...

6 Discussion

TODO

7 Conclusion

TODO

References

A Appendix / supplemental material

A.1 Additional experiments / Proofs of Theorems

TODO